DEU Léonie
Année universitaire 2020 / 2021

DIPLOME D'INGENIEUR DE L'INSTITUT SUPERIEUR DE MECANIQUE DE PARIS (INGENIEUR SUPMECA)

FORMATION INITIALE

STAGE ASSISTANT INGENIEUR

DEU LEONIE

DÉVELOPPEMENT D'UNE APPLICATION DE VISUALISATION DE DONNÉES ATMOSPHÉRIQUES ACQUISES AU SOL

AERIS/ICARE CENTRE DE DONNEES ET SERVICES POUR L'ATMOSPHERE
UNIVERSITE DE LILLE - CITE SCIENTIFIQUE
BATIMENT M3 EXTENSION
59650 VILLENEUVE-D'ASCQ CEDEX - FRANCE

Remerciements

En premier lieu, je tiens à remercier chaleureusement mon maître de stage, M. Nicolas PASCAL, pour sa confiance, sa disponibilité, sa patience, la qualité des enseignements qu'il a pu me dispenser et pour m'avoir partagé sa passion.

Je remercie également M. Jérôme RIEDI, directeur de l'unité AERIS/ICARE, pour avoir répondu très rapidement à ma candidature spontanée et pour m'avoir accordé sa confiance dès le premier entretien.

Je saisis cette occasion pour adresser toute ma gratitude à M. Alfred ROSALES, Directeur des Relations Industrielles de Supméca, pour m'avoir offert l'opportunité de partager mon expérience de stagiaire aux élèves de première année lors d'un webinaire sur le Career Center.

Je désire aussi remercier tous les collègues d'ICARE qui n'ont pas hésité à m'aider pendant mon stage, à répondre à mes questions et à me délivrer leurs conseils avisés. Je retiens également la bonne humeur de toute l'équipe qui a rendu d'autant plus agréable mon expérience au sein d'ICARE.

Un grand merci à mon compagnon M. Théo BODDAERT qui m'a aidé à trouver mon stage, et sans qui je n'aurais pas pu vivre cette expérience unique.

Enfin, je voudrais exprimer ma reconnaissance envers ma famille et mes amis et camarades Julien DEBAUD et Jules JOUFFROY qui m'ont apporté leur soutien moral tout au long de mon stage.

Introduction - Abstract

During his farewell address on 10th January 2017, Barack Obama declared: "Our children won't have time to debate the existence of climate change; they'll be busy dealing with its effects." Whereas the whole world is hit with full force by a first-of-its-kind health crisis, satellite observations made it possible to highlight COVID-19 impact on pollution levels in European cities, which have dropped by 20 or 50 per cent in Paris on May 2020 compared to the same period in 2019. Current results clearly show the direct impact of human activities on air pollution levels and give material to think about how we should remodel our way of living and thinking after this crisis. This ecological and civic conscience motivated me while I was searching for an internship.

From 1st September 2020 to 31st January 2021, I performed an assistant engineer internship within AERIS/ICARE Data and Services Centre. Obtained after a speculative application, I have been called to mind by the various collaborations of ICARE with scientific experts and international space agencies (CNES, NASA, ESA…). Allowing meteorological and climatic models to become more refined and the improvement of long-term climate change's precisions, these projects embodied a splendid initiative which needed to be perpetuated. Thus, I had my heath set on offering my services to ICARE, as a student concerned about ecological issues and respect for the environment.

AERIS/ICARE Data and Services Centre is located in Villeneuve-d'Ascq, within the campus of the University of Lille 1, in the region Hauts-de-France. Created in 2003, its goal is to provide various services to the scientific and research community in fields linked to the atmosphere.

My internship within ICARE comprised the implementation of a virtual infrastructure of services for the analysis and the exploration of atmospheric data thanks to JupyterLab, an integrated development environment. In particular, I succeeded to develop a visualization application of ground-based atmospheric data. Beyond the improvement of my programming skills in Python, this internship made possible to understand how a project is centred on different stakeholders. At last, I had the opportunity to take part in a large-scale European project of atmosphere monitoring. Precisely, I managed to implement my application in the CAMS project in order to visualize real-time ACSM data.

In the first place, to present my internship experience within ICARE, it appears to be pertinent to set out the history, the organisation and products and services offered by the infrastructure. Afterwards, I will consider the internship's surroundings. To conclude with, I will approach the different missions and tasks I carried out and inputs I could extract from it.

SOMMAIRE

Remerciements 2
Introduction - Abstract 3
1. Historique d'ICARE 6
2. Organisation, environnement économique, positionnement du stagiaire ... 8
3. Produits et services proposés par ICARE 9
3.1. La salle des machines 9
3.2. Les produits proposés par ICARE 10
3.3. Les services proposés par ICARE 10
3.3.1. Les services d'accès aux données 10
3.3.2. Les services web autour de la donnée 11
4. Développement durable, responsabilité sociale et environnementale 12
5. Positionnement du stage dans le contexte du centre de recherche 13
6. Déroulement linéaire du stage 13
7. Descriptif du stage selon les objectifs pédagogiques définis 15
7.1. Apprentissage de la Programmation Orientée Objet (POO) 15
7.2. Prise en main de JupyterLab 15
7.2.1. Qu'est-ce que le projet Jupyter ? 15
7.2.2. Qu'est-ce que qu'un notebook ? 16
7.2.3. Qu'est-ce que JupyterLab ? 17
7.3. Développement de la première version de l'application 18
7.3.1. Qu'est-ce que les données ACSM ? 18
7.3.2. Type de fichier envoyé à l'application 19
7.3.3. Langage et librairies utilisées 20
7.3.4. Analyse de l'application développée par le tuteur 21
7.3.5. Aperçu de la première version de mon application 23
7.4. Développement de la deuxième version de l'application 25
7.5. Implémentation de l'application au sein du projet CAMS 27
7.5.1. Qu'est-ce que le projet CAMS ? 27
7.5.2. Comment l'application développée intervient-elle dans ce projet ? 27
7.5.3. Détail du projet CAMS 28
7.5.4. Application développée pour le projet CAMS 29
8. Livrables produits et préconisations pour la suite 31
8.1. Livrables produits 31

8.2. Préconisations pour la suite 31
9. Organisation du travail 31
Conclusion 32
Annexes : Fonctionnement de l'instrument ACSM 33
Annexes : Diagramme de Gantt 34
Table des figures 35
Table des abréviations 36
Glossaire 37

1. Historique d'ICARE

L'action d'ICARE s'inscrit dans le domaine des sciences de l'atmosphère. Les recherches dans ce domaine concernent des thématiques aussi variées que la dynamique, la physique et la chimie atmosphérique. Elles incluent également des travaux plus orientés vers l'étude de l'évolution du climat. Pour effectuer ces recherches, la communauté scientifique utilise des modèles mais aussi des observations qu'elles soient obtenues au sol, au moyen de satellites ou de véhicules aéroportés.

Un des enjeux de ce siècle est de rendre ces données accessibles à une large communauté, que ce soit à des décideurs ou au grand public, pour des activités de recherche ou des applications commerciales. Ces données d'observations, pour être utiles, doivent être étalonnées, validées, homogénéisées. C'est dans ce contexte qu'intervient ICARE.

C'est en 2003 que le centre de recherche ICARE voit le jour, sur l'initiative du CNES, du conseil régional du Nord-Pas-de-Calais et d'un partenariat entre le CNRS et l'Université de Lille. Sa mission est de fournir des services variés à la communauté de chercheurs dans les domaines liés à l'atmosphère, comme les aérosols[1], les nuages, les radiations, le cycle de l'eau et leurs interactions.

ICARE fait partie intégrante d'AERIS, l'infrastructure française de données et services pour l'atmosphère créée en 2014, et constitue l'un de ses quatre centres de données, au même titre qu'ESPRI, SEDOO et SATMOS, respectivement installés à Paris/Palaiseau, Toulouse et Lannion, en région Bretagne.

AERIS, génère des produits à partir des observations, mais également de nombreux services d'aide à l'utilisation des données, d'aide aux campagnes, ou d'interface avec les modèles. Il se positionne comme un acteur incontournable sur la fourniture de données et de services au niveau français mais aussi européen.

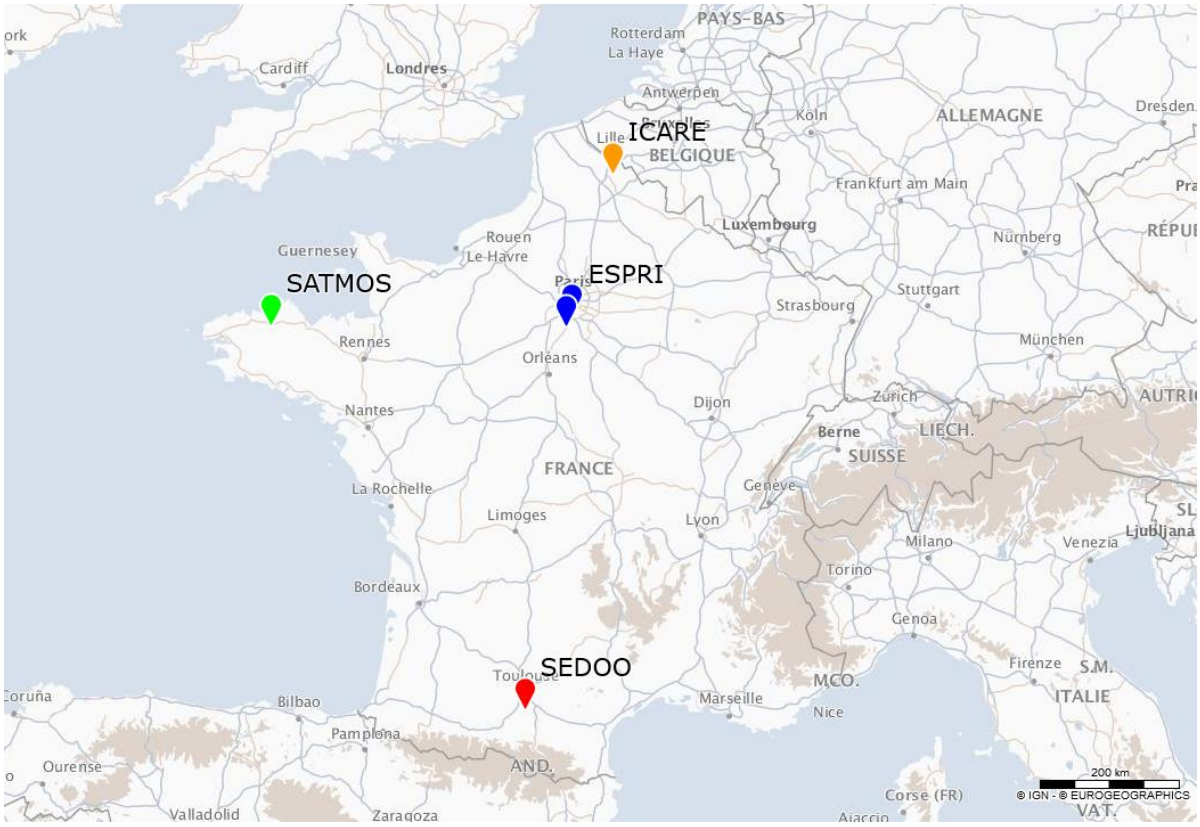


Figure 1 : Localisation des centres de données constitutifs d'AERIS (carte générée par l'Institut National de l'Information Géographique Forestière)

L'essence d'ICARE est la production et la distribution de données de télédétection[2] dérivées des missions d'observation de la Terre menées par le CNES, la NASA et EUMETSAT. L'un des composants principaux d'ICARE est le Centre de Données et Services, situé au sein de l'Université de Lille, qui développe des algorithmes scientifiques et des codes de production, en s'appuyant sur l'expertise de diverses installations de calcul scientifique partenaires, et distribue des produits à la communauté des utilisateurs.

L'objectif premier est de faciliter l'accès et l'utilisation des satellites et des observations au sol des propriétés des aérosols et des nuages atmosphériques, du cycle de l'eau et des radiations. Ainsi, ICARE soutient la recherche en sciences de l'atmosphère et du climat, en collaborant avec des experts français et mondiaux dans ces domaines (CNES, EUMETSAT, ISRO…) et avec des agences spatiales internationales (NASA, ESA…). Ainsi, ICARE contribue chaque année à de nombreux projets collaboratifs, qu'ils soient nationaux ou internationaux.

2. Organisation, environnement économique, positionnement du stagiaire

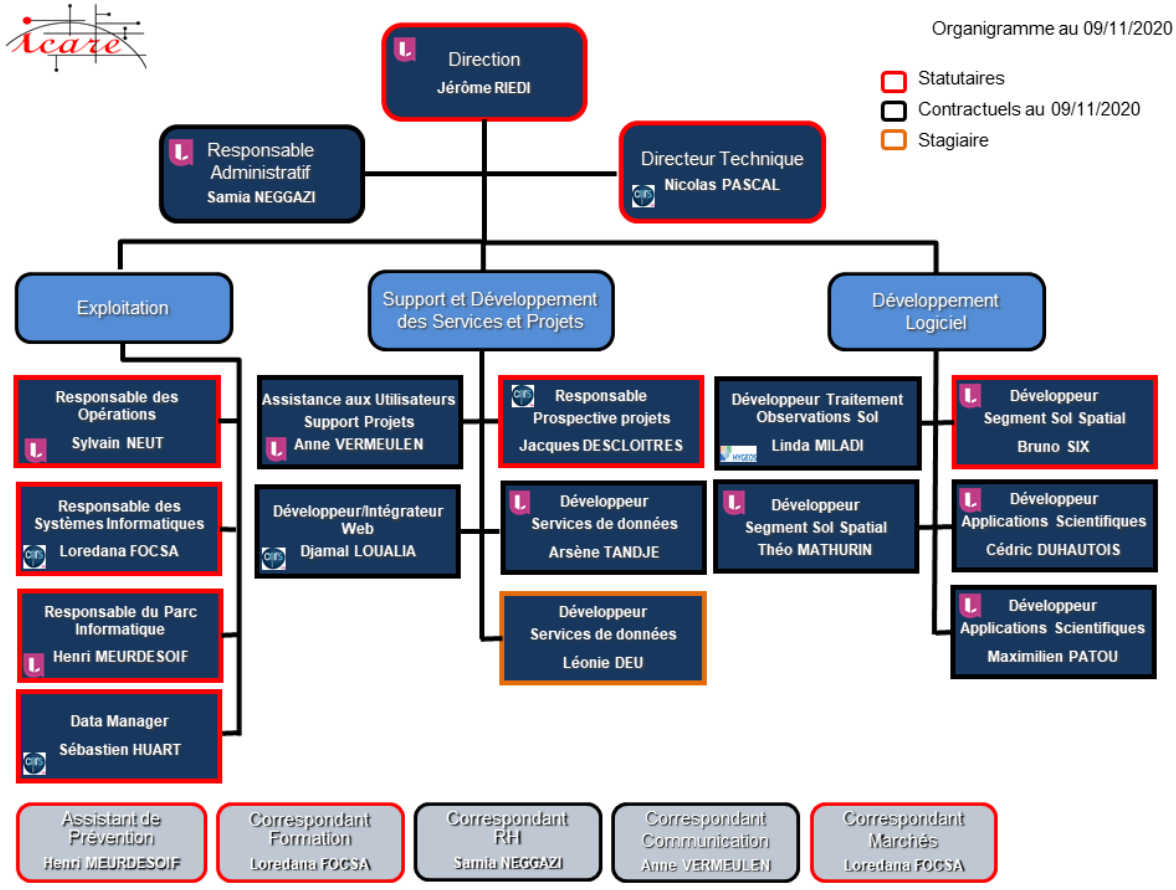


Figure 2 : Organigramme d'ICARE au 09/11/2020

Le Centre de Données et Services ICARE est dirigé par M. Jérôme RIEDI, subordonné par un responsable administratif, Mme Samia NEGGAZI, et par un directeur technique, M. Nicolas PASCAL, mon tuteur de stage. L'organisation est déployée autour de trois branches thématiques qui assurent la cohérence et la cohésion du développement des projets :

- **La branche « Exploitation » :** Elle assure l'installation, la maintenance et le dépannage des machines et systèmes informatiques présents à ICARE, que ce soit dans les bureaux (ordinateurs de fonction ou personnels) ou dans la salle des machines. De plus, elle gère la récupération et le stockage des données en temps réel qui seront exploitées par l'équipe.
- **La branche « Support et Développement des Services et Projets » :** Elle prend en charge les services et projets qui sont soumis à l'équipe par les utilisateurs. Son rôle est double : analyser les besoins pour développer de nouveaux services, mais aussi fournir une assistance aux utilisateurs. Ainsi, la branche support et développement est chargée du développement et de

l'intégration du site web d'ICARE, mais également du développement de services de données. C'est dans ce contexte qu'évolue le sujet de mon stage.

- **La branche « Développement Logiciel » :** Cette branche, entièrement consacrée au développement, assure la production de code et d'applications scientifiques répondant aux besoins des utilisateurs. Son champ d'action s'étend des données atmosphériques acquises au sol aux données atmosphériques spatiales collectées par des satellites.

L'ensemble des branches est coordonné par le directeur technique afin d'assurer la cohérence des missions et la productivité de l'équipe. Bien qu'ayant en théorie des rôles bien définis, les branches sont en constante interaction et effectuent des actions en parallèle afin de répondre au mieux aux attentes des scientifiques.

3. Produits et services proposés par ICARE

ICARE propose une variété de produits et services à la communauté scientifique, en répondant à des appels à projets et aux demandes des utilisateurs. Ces données et services sont accessibles sur leur site internet www.icare.univ-lille.fr. Ce site est rédigé en anglais afin de permettre aux utilisateurs de toutes nationalités de naviguer facilement sur l'interface. Certains services nécessitent une authentification à l'aide d'un login et d'un mot de passe, car ils sont réservés à certains utilisateurs.

3.1. La salle des machines

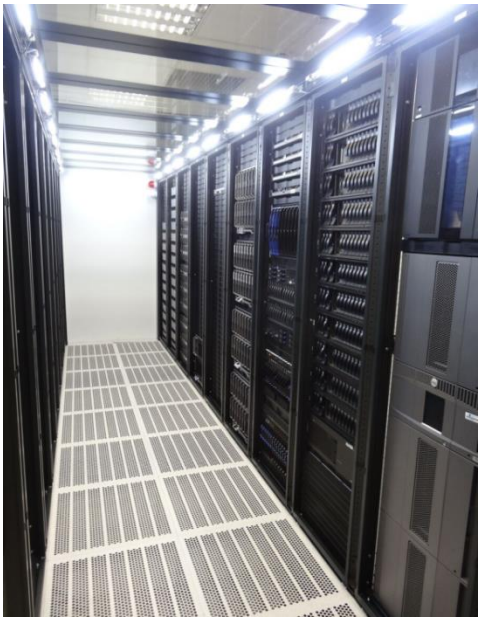


Figure 3 : Photographie du SAS réfrigéré de la salle des machines

La salle des machines est une composante indispensable au fonctionnement du Centre de Données et Services ICARE car elle permet la mise à disposition de produits et services aux utilisateurs. Elle se compose entre autres d'un **SAS réfrigéré** et d'une **librairie de sauvegarde**. Les machines du SAS réfrigéré accueillent des serveurs de **stockage** et de **calcul** (cluster[3]). Ces serveurs fonctionnent 24h/24 et 7j/7. La librairie de sauvegarde, quant à elle, contient la sauvegarde de toutes les données en ligne, des espaces utilisateurs mais aussi l'archivage des anciennes données collectées et du code qui ne sont utilisés pour aucun projet en cours, en vue d'une éventuelle réutilisation.

3.2. Les produits proposés par ICARE

Les produits proposés par ICARE sont essentiellement des données satellites issues de missions spatiales auxquelles ICARE participe, mais aussi des données sol et de modèle. ICARE (ou un partenaire) collecte ces données brutes – appelées données de niveau 0 ou 1 – puis effectue des traitements, fournissant des produits de différents niveaux. Les produits de niveaux supérieurs intègrent des algorithmes afin d'extraire des informations des données brutes et de calculer de nouveaux paramètres scientifiques.

ICARE met à disposition des utilisateurs des données mais également des visualisations de ces données.

3.3. Les services proposés par ICARE

3.3.1. Les services d'accès aux données

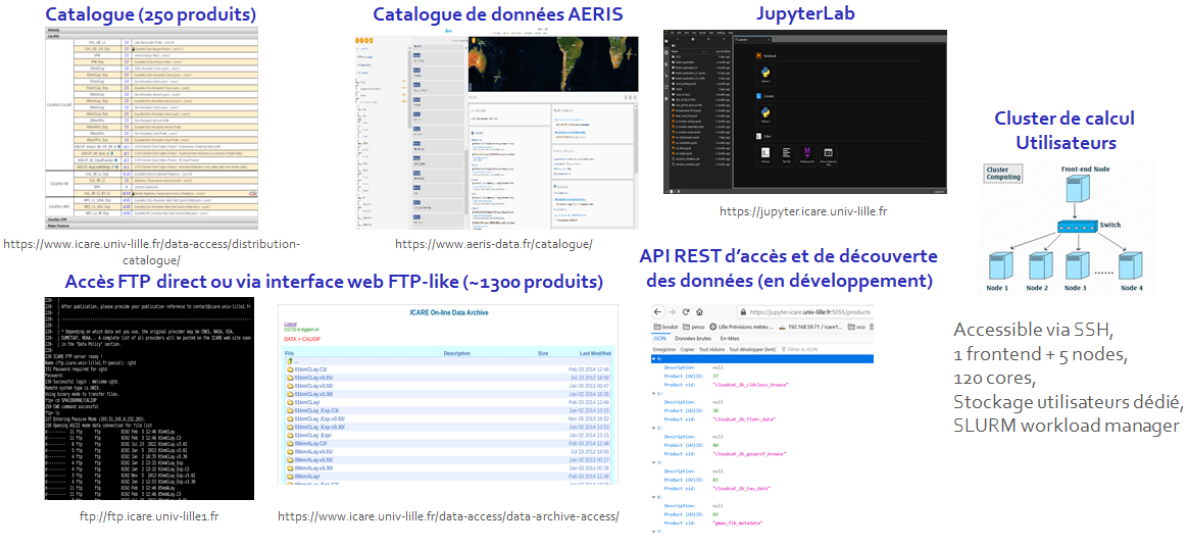


Figure 4 : Résumé des services d'accès aux données proposés par ICARE

- Le **catalogue** permet de naviguer dans la base de données des produits ICARE. Il est accessible sur le site d'ICARE.

- Le **catalogue de données AERIS** permet de naviguer dans la base de données AERIS, regroupant les produits générés par ICARE et par les autres centres de données d'AERIS. Il est accessible sur le site d'AERIS.
- L'interface **JupyterLab**, en cours de déploiement, permet aux utilisateurs de manipuler un environnement de développement intégré (IDE) complet et ergonomique. Il sera détaillé par la suite.
- L'**accès FTP**[4] s'effectue par accès direct ou via une interface web FTP-like. Il permet aux utilisateurs d'accéder aux fichiers présents sur le serveur.
- L'**API REST**[5], en cours de développement, permet aux utilisateurs de l'API d'utiliser des appels HTTP pour demander une ressource ou envoyer des données au serveur.
- Le **cluster de calcul** offre aux utilisateurs un environnement Linux très similaire à l'environnement de production d'ICARE, dans lequel ils peuvent exécuter leurs propres codes et accéder en ligne à l'ensemble des archives ICARE.

3.3.2. Les services web autour de la donnée

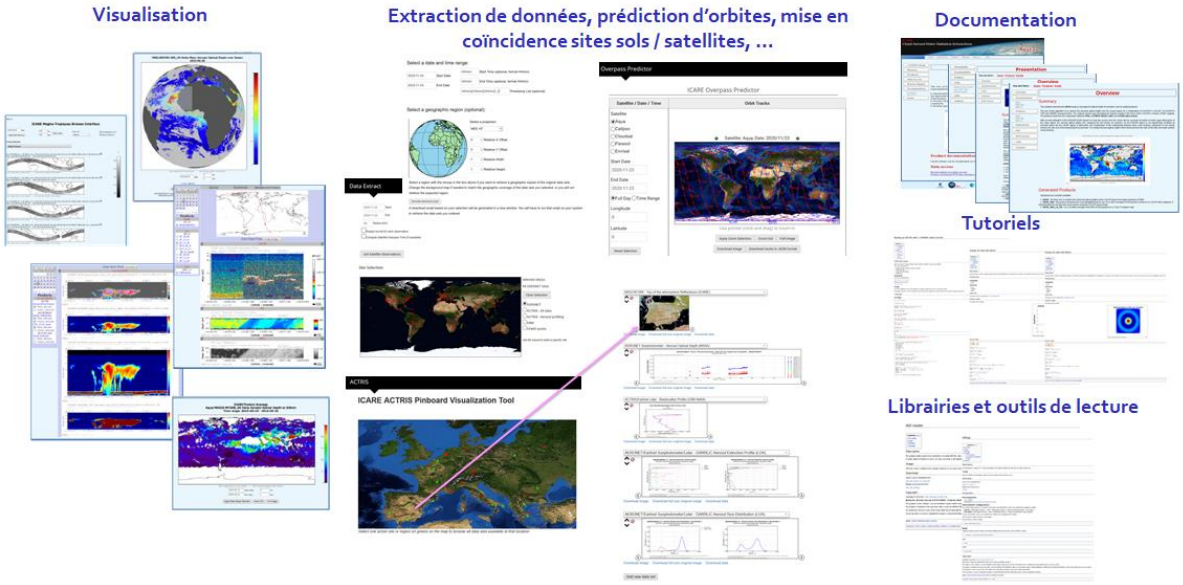


Figure 5 : Résumé des services web autour de la donnée proposés par ICARE

Je ne vais pas détailler l'ensemble des services web disponibles sur le site d'ICARE, car cela serait beaucoup trop long. Néanmoins, les principaux services sont les services :

- **De visualisation :** Ils fournissent des images satellites sol agrémentées d'informations pertinentes, à savoir des paramètres issus de calculs scientifiques.

- **D'extraction de données :** Une carte interactive permet de récupérer les données satellite d'un site particulier associé à un projet particulier.
- **De prédiction d'orbites :** Les orbites des satellites sont projetées sur une carte satellite du monde agrémentée d'horaires. Ainsi, il est possible d'estimer à quelle heure un satellite passera au-dessus d'un point précis du globe. Les satellites disponibles sont les satellites des missions auxquelles ICARE participe.
- **Tutoriels :** Des tutoriels sont mis à la disposition des utilisateurs dans le domaine de la programmation et de la manipulation de données. Le but est de fournir des codes simples et des exemples faciles à reproduire, pour des problématiques classiques en programmation pour la data science[6].
- **Librairies et outils de lecture :** Ils ont pour but d'aider les utilisateurs à manipuler, analyser et visualiser les ensembles de données et les formats de fichiers disponibles dans la base de données.

Enfin, de nouveaux services web sont en cours de déploiement, notamment des **services *dashboard***[7] de visualisation, d'analyse et d'inter-comparaison des données : c'est dans ce cadre qu'intervient mon stage.

4. Développement durable, responsabilité sociale et environnementale

La question de l'empreinte des activités de recherche sur l'environnement est un sujet qui concerne l'unité ICARE à plusieurs titres, d'abord en raison de la communauté scientifique qu'elle sert et de sa thématique, mais encore plus directement en raison de la consommation énergétique de son infrastructure, qui s'élève à environ **28 000 kWh/mois** (consommation mensuelle de 70 ménages français).

Ainsi, ICARE est en réflexion afin de rejoindre le collectif **« Labos 1point5 »** qui a pour but d'emmener l'ensemble de la communauté de recherche française dans une démarche de transformation axée sur la réduction de son empreinte environnementale. L'objectif serait donc pour ICARE de travailler sur l'évaluation de son empreinte et sur la mise en place d'une politique dans ce domaine.

Sur le même thème, ICARE s'intéresse aux actions menées par le GDS (Groupe De Service) CNRS **EcoInfo**, réunissant ingénieurs, chercheurs et étudiants autour d'un objectif commun : agir pour réduire les impacts (négatifs) environnementaux et sociétaux des TICs (Technologies de l'Information et de la Communication). Ainsi, EcoInfo travaille sur plusieurs problématiques pour limiter les impacts écologiques liés aux data centers.

5. Positionnement du stage dans le contexte du centre de recherche

Le sujet du stage est : **« Mise en place d'une infrastructure virtuelle de services pour l'analyse et l'exploration de données atmosphériques à l'aide de JupyterLab »**.

Concrètement, l'idée est de développer une **application de visualisation de données atmosphériques acquises au sol** afin que les utilisateurs puissent afficher leurs données à l'écran et interagir avec les graphes.

Cette activité s'inscrit dans l'activité de l'entreprise au quotidien dans la mesure où elle représente une mission dédiée à un développeur de services de données au sein de la branche « Support et Développement des Services et Projets » (cf. figure 2 p.8).

Ainsi, ce projet représente un projet parmi tous ceux qui sont traités quotidiennement par l'équipe d'ICARE.

6. Déroulement linéaire du stage

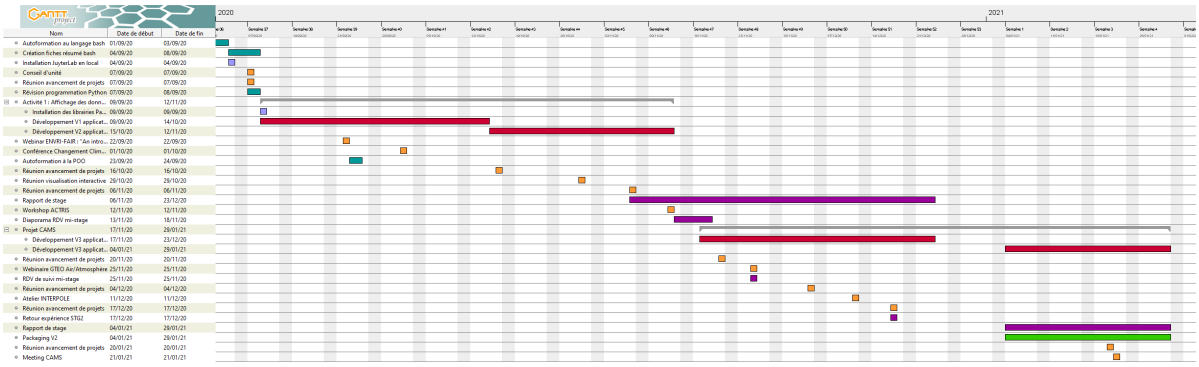


Figure 6 : Diagramme de GANTT de la chronologie du stage (version agrandie en annexes)

Mon stage a débuté le 1er septembre 2020, avec la découverte de l'environnement Linux et l'auto-formation au langage Bash afin de pouvoir travailler correctement sur la machine mise à ma disposition fonctionnant sous CentOS 7. Ensuite, j'ai moi-même installé JupyterLab en local sur ma machine, ainsi que ses dépendances et toutes les librairies Python dont j'avais besoin.

La première réunion à laquelle j'ai assisté est un conseil d'unité qui s'est déroulé le 7 septembre 2020, qui a lieu une fois par an en début d'année scolaire. Le but était de voter le règlement intérieur de l'unité et de faire un point sur les postes à pourvoir. Ensuite, une revue de projet a été organisée, afin de faire un bilan des activités réalisées par les employés durant l'été.

J'ai par la suite effectué une révision de la programmation en langage Python. Une fois ce travail effectué, j'ai pu commencer à développer la première version de mon application en m'appuyant sur l'application préalablement développée par mon tuteur. J'ai en même temps réalisé une auto-formation à la Programmation Orientée Objet (POO) en Python afin de pouvoir développer mon application. Après un peu moins d'un mois, la première version était fonctionnelle.

Suite à des échanges avec mon tuteur, je me suis ensuite lancée dans la programmation d'une deuxième version de mon application plus poussée et plus adaptée aux besoins des utilisateurs. J'ai eu la chance de pouvoir présenter mon application aux membres de l'équipe lors d'une réunion sur le thème de la visualisation interactive, ainsi qu'à des scientifiques pendant le Workshop ACTRIS du 12 novembre 2020 lors duquel mon application a suscité l'intérêt et la curiosité des participants. Ainsi, les conseils et remarques recueillies m'ont permis d'améliorer mon application. Après trois semaines de développement, la deuxième version de mon application était prête.

Puis, j'ai entamé la rédaction de mon rapport de stage et confectionné un diaporama en vue de la réunion de suivi mi-parcours du stage avec M. ROSALES.

Entre-temps, mon tuteur a décidé de m'impliquer dans le projet européen CAMS car la deuxième version de mon application était convaincante et car j'avais rapidement progressé. Ainsi, j'ai commencé à développer une troisième version de mon application afin de contribuer au projet.

Tout au long de ces 5 mois, j'ai pu participer à de nombreuses réunions d'avancement de projets qui m'ont permis d'améliorer mon aisance à l'oral en public et de perfectionner mes capacités de synthèse. De plus, j'ai eu l'opportunité d'assister à des réunions sur le thème des sciences de l'atmosphère qui m'ont permis d'en apprendre plus sur ce domaine. J'ai également pu assister à la conférence sur le changement climatique de Valérie MASSON-DELMOTTE, paléoclimatologue mondialement reconnue et citée par la revue *Nature* comme l'une des 10 scientifiques ayant marqué l'année 2018.

Enfin, j'ai également eu l'opportunité de présenter mon stage et mon expérience aux élèves de première année lors d'un webinaire de retour d'expérience, exercice inédit dans l'histoire de Supméca. C'est lors de cette réunion que j'ai été interpellée par M. Erik KERSTEL, professeur à l'Université de Grenoble et directeur du Centre Spatial Universitaire de Grenoble, afin de livrer à son doctorant M. Markus MILTNER la deuxième version de mon application. Leur objectif serait d'intégrer mon application dans leur projet de développement d'un instrument pour l'analyse isotopique de l'eau embarqué à bord d'un A350 pour la campagne IAGOS, réseau d'avions commerciaux équipés pour la surveillance du climat.

7. Descriptif du stage selon les objectifs pédagogiques définis

7.1. Apprentissage de la Programmation Orientée Objet (POO)

Suite aux recommandations de mon tuteur, je me suis lancée dans l'apprentissage de la POO avant de commencer à développer mon application. En effet, il était nécessaire d'avoir recours aux objets afin d'assurer la cohérence de mon code et de faciliter la gestion des éléments clés du *dashboard*.

J'ai donc effectué une auto-formation à la POO en m'appuyant sur diverses ressources disponibles. Le concept de Programmation Objet étant assez complexe, j'ai d'abord commencé par visionner quelques vidéos introductives sur les principaux concepts de la POO en Python sur une chaîne YouTube recommandée par Maximilien, un membre de l'équipe ICARE : la chaîne FormationVidéo.

Ensuite, j'ai étudié le cours sur la POO en Python du site « Zeste de savoir » disponible à l'adresse suivante : https://zestedesavoir.com/tutoriels/1253/la-programmation-orientee-objet-en-python/.

Enfin, j'ai parcouru le PDF du cours Python de l'Université de Paris gracieusement prêté par Maximilien. Après avoir lu les premiers chapitres pour réviser les bases de la programmation en Python, je me suis intéressée au chapitre 19 intitulé « Avoir la classe avec les objets ».

Ainsi, en quelques jours, grâce à de la lecture de code et à de la pratique, j'ai pu saisir la puissance et l'utilité des classes pour le langage Python, et par extension pour tout langage de programmation.

7.2. Prise en main de JupyterLab

Afin de développer mon application, je me suis appuyée sur JupyterLab, une extension du projet Jupyter : il m'a donc fallu apprendre à manipuler ces outils.

7.2.1. Qu'est-ce que le projet Jupyter ?



Jupyter est une application web de programmation dont la première version remonte à 2015. Il s'appuie sur des noyaux permettant l'usage de langages de programmation.

Initialement, les langages supportés par Jupyter étaient Julia, Python et R, dont la contraction a donné naissance au nom Jupyter.

Jupyter est une évolution du projet IPython. Jupyter permet de réaliser des calepins ou notebooks, c'est-à-dire des programmes contenant à la fois du texte en markdown[8] et du code en Julia, Python, R... Ces calepins sont utilisés en science des données pour explorer et analyser des données.

Aujourd'hui, cette application web supporte plus de 50 langages. Seuls les noyaux pour les langages Julia, Python, R et Scala sont maintenus par les développeurs principaux du projet. Les autres sont développés par différentes communautés de développeurs.

7.2.2. Qu'est-ce que qu'un notebook ?

Un notebook Jupyter combine des sections en langage naturel mises en forme avec la syntaxe "Markdown" et des sections en code Python, Julia, R ou autres langages.

Il permet la création et le partage de documents constitués d'une liste ordonnée de cellules d'entrée et de sortie. Les cellules peuvent contenir, entre autres, du code, du texte au format Markdown, des formules mathématiques ou des contenus médias (Rich Media).

Les notebooks peuvent être sauvegardés au format JSON avec l'extension ".ipynb".

Jupyter Notebook met à disposition un environnement qui répond parfaitement aux exigences et au flux de travail dans le domaine de la science des données et de la simulation. Une seule et unique instance permet à l'utilisateur d'écrire du code, de l'accompagner d'explications et de l'exécuter, mais aussi de visualiser des données, d'exécuter des calculs et de vérifier les résultats obtenus. C'est en particulier à l'étape du prototype qu'on apprécie la possibilité offerte de loger tous les codes dans des cellules indépendantes, ce qui permet de tester individuellement des blocs de code particuliers. Grâce à de nombreux noyaux complémentaires, Jupyter n'est pas limité à Python comme langage de programmation, ce qui procure une énorme flexibilité de codage et d'analyse.

Voici quelques-uns des principaux usages qu'on peut faire de Jupyter Notebook :

- **Nettoyage des données :** faire le tri entre les données importantes et celles qui ne le sont pas dans l'analyse des ensembles de mégadonnées.
- **Modélisation statistique :** méthode mathématique permettant d'établir la probabilité de répartition d'une caractéristique particulière.
- **Création et mise en œuvre de modèles d'apprentissage automatique :** étude, programmation et apprentissage de modèles.
- **Visualisation de données :** représentation graphique de données pour faire apparaître des structures, des tendances, des relations, etc.

Pour illustrer l'usage du notebook Jupyter, prenons l'exemple de la visualisation de données.

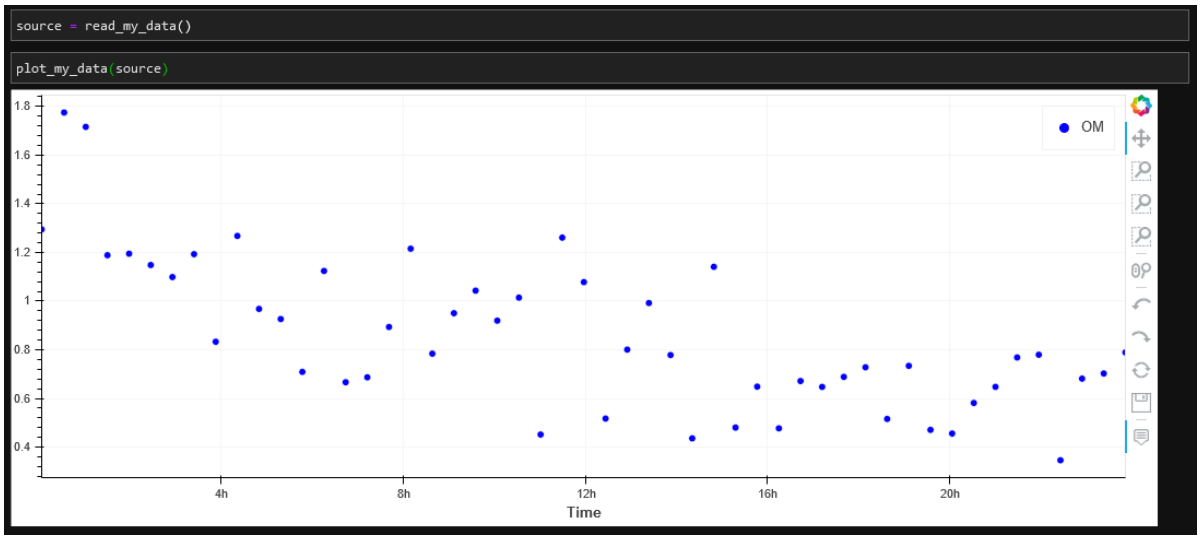


Figure 7 : Exemple de notebook Jupyter de visualisation de données

Dans cet exemple, l'exécution de la première cellule permet de lire, de mettre en forme et de stocker des données dans une variable `source` grâce à une fonction `read_my_data` préalablement définie. Cette exécution ne retourne rien, voilà pourquoi la cellule de sortie n'est pas visible.

En revanche, l'exécution de la deuxième cellule renvoie un graphe : elle permet l'affichage des données stockées dans l'objet `source` grâce à une fonction `plot_my_data` préalablement définie.

Ainsi, les notebooks permettent une exploration et un affichage rapides de jeux de données, qui feront de Jupyter Notebook un outil incontournable de la data science.

Dépassés par le succès des notebooks, les développeurs ont dû répondre à beaucoup de demandes de développements, et les notebooks ont vite évolué avec notamment une nouvelle interface de développement plus évoluée : le JupyterLab.

7.2.3. Qu'est-ce que JupyterLab ?

JupyterLab est un dérivé du projet Jupyter. C'est un IDE, à savoir un Environnement de Développement Intégré, à l'instar de Visual Studio Code. Cette interface utilisateur-web de nouvelle génération combine la puissance des notebooks et la possibilité d'utiliser différents outils en même temps. Il est ainsi possible de manipuler des notebooks, mais aussi des fichiers au format Markdown, des fichiers texte, ainsi que d'ouvrir un terminal ou une console.

Grâce à cet environnement de travail, j'ai pu manipuler des notebooks afin de tester des portions de code, ouvrir les fichiers contenant les données à visualiser ainsi que

facilement modifier des fichiers Python, ce qui a permis d'accélérer le développement de mon application.

JupyterLab est en constante évolution mais apparaît aujourd'hui comme une solution de développement complètement open source parfaitement adaptée au *data scientist* et à ses besoins. Le succès est tel que JupyterLab remplacera probablement à terme Jupyter Notebook.

7.3. Développement de la première version de l'application

Ainsi, après avoir étudié la POO et pris en main JupyterLab, j'avais à présent toutes les clés en main afin de mener à bien le développement de mon application de visualisation de données atmosphériques en fournissant plusieurs versions, détaillées ci-après. Les données que j'ai dû visualiser sont des données atmosphériques acquises au sol, plus particulièrement des **données ACSM**.

7.3.1. Qu'est-ce que les données ACSM ?

Les données ACSM sont des données issues de l'instrument de mesure appelé ACSM (*Aerosol Chemical Speciation Monitor*). Ce moniteur de spéciation chimique des aérosols permet, comme son nom l'indique, de mesurer en temps réel la **composition chimique des particules d'aérosol présentes dans l'air**.

Cet instrument, fabriqué par Aerodyne Research, unique entreprise fournissant des ACSM dans le monde, a une valeur d'environ 180 000€.

L'ACSM est essentiellement composé d'un **spectromètre de masse**. Une fiche résumant le fonctionnement de cet instrument est donnée en annexe.



Figure 8 : Photographie d'un ACSM

Cet instrument mesure la **concentration** des particules d'aérosol dans l'air en µg/m^3, à savoir :

- La matière organique (Org) ;
- Les nitrates (NO3) ;
- Les sulfates (SO4) ;
- Les ammoniums (NH4) ;
- Les chlorures non marins (Chl ou Cl).

Par la suite, ces espèces seront appelées **espèces ACSM**.

Les données fournies permettent de mieux comprendre les **sources d'émission de particules fines**.

En effet, la nature chimique renseigne sur les sources. NH_4NO_3 provient de la combustion et des émissions agricoles. Les combustions (trafic & industries en été ; chauffage en hiver) émettent du NO_2, tandis que les émissions agricoles du NH_3 (élevages & épandages).

Ces deux gaz se combinent si les températures sont fraîches pour former des particules de NH_4NO_3, détectables par l'ACSM.

7.3.2. Type de fichier envoyé à l'application

Les fichiers envoyés à l'application sont des fichiers produits par l'ACSM puis reformatés au **format NASA-Ames**[9], agrémentant le fichier d'informations importantes permettant de lire, de comprendre et d'interpréter les données, et fournissant une architecture commune à tous les fichiers.

```
04 1001
Riffault, Véronique
FR07L, Ecole Nationale Supérieure Mines-Télécom Lille Douai, IMT Lille Douai,
PASCAL, Nicolas; Riffault, Véronique
ACTRIS  COLOSSAL
1 1
2018 07 20 2020 09 08
0.041667
Days from the file reference point (start_time)
25
1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
9999.999999 99999.999 99999.999 9.999 99999.999 99999.999 9.999 99999.999 999
end_time of measurement, days from the file reference point
organic_mass, ug/m3, Statistics=arithmetic mean
organic_mass, ug/m3, Statistics=uncertainty
numflag, no unit
sulphate_total, ug S/m3, Statistics=arithmetic mean
sulphate_total, ug S/m3, Statistics=uncertainty
numflag, no unit
nitrate, ug N/m3, Statistics=arithmetic mean
nitrate, ug N/m3, Statistics=uncertainty
numflag, no unit
ammonium, ug N/m3, Statistics=arithmetic mean
ammonium, ug N/m3, Statistics=uncertainty
numflag, no unit
chloride, ug/m3, Statistics=arithmetic mean
chloride, ug/m3, Statistics=uncertainty
numflag, no unit
organic_mass, ug/m3, Fraction=Org_44, Statistics=arithmetic mean
```

start_time	end_time	Org	err_Org	numFlag_Org	SO4	err_SO4	numFlag_SO4	NO3	err_N
0.000000	0.041667	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.041667	0.083333	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.083333	0.125000	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.125000	0.166667	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.166667	0.208333	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.208333	0.250000	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.250000	0.291667	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.291667	0.333333	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.333333	0.375000	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.375000	0.416667	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.416667	0.458333	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.458333	0.500000	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.500000	0.541667	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.541667	0.583333	99999.999	99999.999	0.999	99999.999	99999.999	0.999	99999.9	
0.583333	0.625000	9.606	0.076	0.000	0.438	0.005	0.000	1.848	0.006	0.000	2.317
0.625000	0.666667	8.890	0.074	0.000	0.427	0.005	0.000	1.759	0.005	0.000	2.122
0.666667	0.708333	9.272	0.072	0.000	0.501	0.005	0.000	1.818	0.006	0.000	2.443
0.708333	0.750000	9.937	0.070	0.000	0.502	0.005	0.000	1.995	0.006	0.000	2.610
0.750000	0.791667	10.687	0.069	0.000	0.539	0.005	0.000	2.065	0.006	0.000	2.57
0.791667	0.833333	10.251	0.069	0.000	0.500	0.005	0.000	1.977	0.006	0.000	2.57
0.833333	0.875000	11.123	0.076	0.000	0.491	0.006	0.000	1.596	0.006	0.000	2.12
0.875000	0.916667	10.453	0.076	0.000	0.474	0.006	0.000	1.433	0.005	0.000	1.94
0.916667	0.958333	7.192	0.074	0.000	0.379	0.005	0.000	0.966	0.004	0.000	1.412
0.958333	1.000000	6.053	0.071	0.000	0.405	0.005	0.000	0.975	0.004	0.000	1.356
1.000000	1.041667	5.913	0.065	0.000	0.377	0.005	0.000	1.129	0.004	0.000	1.523
1.041667	1.083333	6.846	0.059	0.000	0.366	0.004	0.000	1.605	0.005	0.000	1.967
1.083333	1.125000	6.462	0.054	0.000	0.316	0.004	0.000	1.918	0.005	0.000	2.272
1.125000	1.166667	5.559	0.051	0.000	0.289	0.004	0.000	1.886	0.005	0.000	2.095

Figure 9 : À gauche : extrait de l'en-tête d'un fichier ACSM au format NASA-Ames, à droite : extrait des données ACSM de ce fichier

Chaque fichier est composé de deux parties :

- En début de fichier, l'**en-tête de fichier** comprend les informations sur les données (métadonnées) permettant leur lecture et leur compréhension :
  - le numéro du fichier dans l'ensemble de données ;
  - le nombre de lignes de l'en-tête ;
  - le FFI[10] (indices de format de fichier) qui définit sans ambiguïté la structure de la section de données et les informations supplémentaires requises sur le format des données ;
  - le nombre, la nature et les unités de tous les types de variables classées comme dans la section des données ;
  - des informations sur la source des données (nom et affiliation des fournisseurs de données, expérience, instrumentation, modèle utilisé, etc.) ;
  - des informations sur les données, le traitement des données et la qualité des données (lieu, date, date de révision, etc.).

Des champs de commentaire sont fournis à la fin de l'en-tête pour tout type d'informations supplémentaires qui ne rentreraient pas dans les lignes formatées prédéfinies.

- Les **données ACSM** sont enregistrées dans les lignes suivant l'en-tête :
  - Chaque ligne correspond à un recueil de données dans un intervalle de temps donné.
  - Pour chaque ligne, la première colonne correspond à la date de début de recueil des données, et la seconde à la date de fin. Plus précisément, ces informations sont exprimées en nombre de jours écoulés depuis la date de début de collecte des données par l'ACSM.
  - Les autres colonnes disponibles correspondent aux concentrations des espèces ACSM : Org, SO4, NO3, NH4, Chl, ainsi que Org 44, Org 43 et Org 60 (les fractions spécifiques constitutives de la matière organique).
  - Pour chaque espèce, en plus de la concentration, une erreur sur la concentration est fournie ainsi qu'un flag (nombre décimal indiquant la qualité de la donnée). Si le flag est nul, la donnée est considérée comme valide.

Le fichier utilisé pendant le développement de l'application contient des données enregistrées **toutes les heures** pendant environ **5 mois**.

7.3.3. Langage et librairies utilisées

Afin de développer mon application, j'ai utilisé le langage Python au sein de JupyterLab, agrémenté de trois librairies principales :



- La librairie **Pandas** : Il s'agit d'une librairie de manipulation de données. Elle fournit des structures de données puissantes et simples à utiliser, ainsi que les moyens d'effectuer rapidement des opérations sur ces structures. Elle offre la possibilité de manipuler des tableaux de données avec des étiquettes de colonnes et de lignes. Ces tableaux sont appelés DataFrames, similaires aux dataframes sous R. On peut facilement lire/écrire ces DataFrames à partir ou vers un fichier tabulé et tracer des graphes à partir de ces DataFrames. Les types de fichiers pris en charge par Pandas sont nombreux. En particulier, j'ai utilisé cette librairie pour lire des fichiers CSV[11].



- La librairie **NumPy (Numerical Python)** : Il s'agit de la bibliothèque de calcul scientifique la plus populaire en Python. Ainsi, elle permet d'effectuer les calculs scientifiques de base et de manipuler assez facilement les tableaux multidimensionnels. Je l'ai utilisée pour effectuer du calcul numérique. Elle permet également de faire de l'algèbre linéaire, du calcul matriciel…



- La librairie **Bokeh** : Il s'agit d'une librairie pour la visualisation interactive conçue pour les navigateurs modernes. Je l'ai utilisée pour sa variété d'outils de visualisation faciles à prendre en main. Elle fournit une construction élégante et concise de graphiques polyvalents et offre une interactivité de haute performance sur des ensembles de données volumineux ou en continu. Bokeh peut aider tous ceux qui souhaitent créer rapidement et facilement des tracés interactifs, des *dashboards* et des applications de données. Durant mon stage, j'ai d'ailleurs pu participer à l'amélioration de cette librairie en postant un ticket sur le GitHub associé à propos d'un dysfonctionnement rencontré au cours de la programmation.

7.3.4. Analyse de l'application développée par le tuteur

Afin de développer mon application, mon tuteur m'a proposé de m'appuyer sur une application de visualisation développée par ses soins. Le but était de reproduire cette application en analysant son interface graphique sans avoir accès au code, et de l'améliorer, notamment en ajoutant une **couche interactive** à l'aide de librairie Bokeh.

De plus, l'objectif était de **comparer les performances** de la librairie de visualisation Bokeh par rapport à la librairie de visualisation Plotly version JavaScript utilisée par mon tuteur.

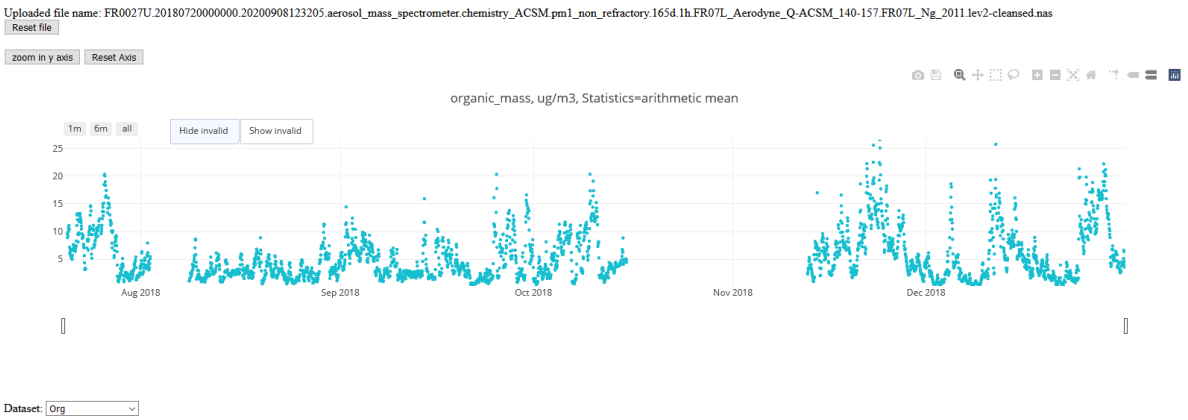


Figure 10 : Vue d'ensemble de l'application développée par mon tuteur avec visualisation des données du fichier de la figure 9

L'application de mon tuteur se compose de divers objets :

- Au démarrage, un *FileInput* permet à l'utilisateur de soumettre le fichier ACSM dont on veut visualiser les données en cliquant sur le bouton "*Parcourir…*".
- Ensuite, un graphe principal apparaît à l'écran : l'axe des abscisses représente le temps et l'axe des ordonnées correspond aux valeurs de l'élément à l'écran. La visualisation de la série temporelle s'effectue à l'aide d'un nuage de points (*scatter plot*). Une barre d'outils (*tool bar*) attachée au graphe en haut à droite permet essentiellement de zoomer et de se déplacer sur le graphe. De plus, lorsque l'utilisateur passe la souris sur un point du graphe, une info-bulle (*hover tool*) apparaît, affichant la date et l'ordonnée.
- Un outil interactif (*widget*) nommé "*Dataset*" permet de changer l'élément visualisé à l'aide d'un menu déroulant. Ce menu déroulant propose toutes les colonnes du fichier, à l'exception évidente des colonnes de temps. Si l'utilisateur change le *dataset*, le titre du graphe est dynamiquement mis à jour.
- Enfin, une série de 3 boutons permet de changer l'échelle de l'axe des abscisses, en choisissant 1 mois, 6 mois ou la plage de données complète.
- Un duo de boutons "*Hide invalid*" et "*Show invalid*" permet de cacher ou d'afficher la plage de données invalides. Cette plage de données correspond à l'union des intervalles de temps sur lesquels le flag de l'élément à l'écran est non nul.

7.3.5. Aperçu de la première version de mon application

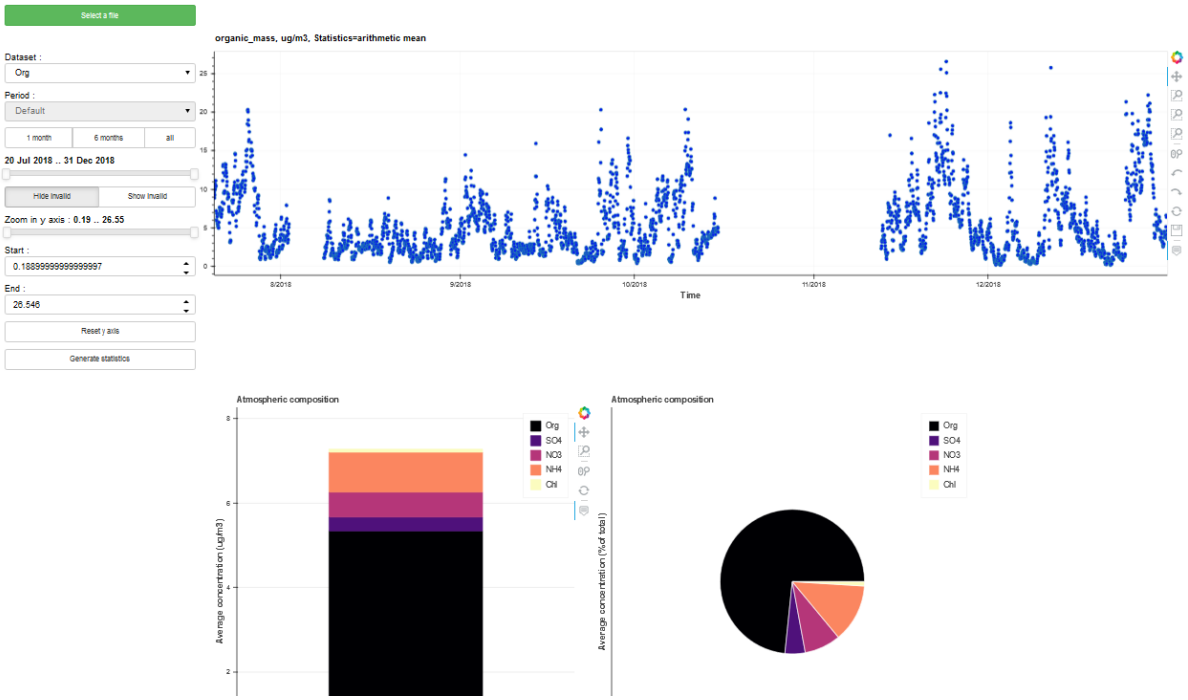


Figure 11 : Vue d'ensemble de la première version de mon application avec visualisation des données du fichier de la figure 9

Sur le *dashboard*, on retrouve un *FileInput* et un graphe principal similaires à ceux de l'application de mon tuteur. La barre d'outils attachée à ce graphe est cependant plus riche que dans l'application de référence. On y trouve notamment :

- un *pan tool*, permettant de se déplacer sur le graphe à l'aide de la souris ;
- un *box zoom tool* classique, grâce auquel l'utilisateur peut zoomer sur le graphe en dessinant un rectangle à l'aide de la souris ;
- un *box zoom tool (x-axis)*, permettant de zoomer uniquement sur l'axe des abscisses (l'échelle de l'axe des ordonnées restant inchangée) ;
- un *box zoom tool (y-axis)*, permettant de zoomer uniquement sur l'axe des ordonnées (l'échelle de l'axe des abscisses restant inchangée) ;
- un *wheel zoom tool*, permettant de zoomer à l'aide de la molette de la souris ;
- un *undo tool* pour annuler la dernière action effectuée ;
- un *redo tool* pour rétablir la dernière action effectuée ;
- un *save tool* pour sauvegarder le graphe en tant qu'image.

La nouveauté réside dans le **panneau interactif** situé à gauche du graphe principal. Une grande quantité de *widgets* ont été ajoutés afin de permettre à l'utilisateur d'interagir avec le graphe :

- Un *date slider*, offrant la possibilité à l'utilisateur de modifier l'échelle de l'axe des abscisses en faisant glisser les bornes inférieures et supérieures sur l'axe des temps ;
- Un *slider* "*Zoom in y axis*", dont l'utilisation permet de modifier l'échelle de l'axe des ordonnées en faisant glisser les bornes inférieures et supérieures sur l'axe ;
- Deux *spinners* "*Start*" et "*End*", permettant de modifier respectivement les bornes inférieure et supérieure de l'axe des ordonnées en entrant une valeur au clavier ;
- Un bouton "*Reset y axis*" pour réinitialiser les bornes inférieure et supérieure de l'axe des ordonnées ;
- Un bouton "*Generate statistics*" générant des statistiques classiques pour l'élément à l'écran (à condition que celui-ci soit une espèce ACSM) : minimum, maximum, moyenne et écart-type. Les calculs sont effectués sur l'ensemble du *dataset*, et ne changent pas si l'utilisateur zoome sur le graphe.
- Un menu déroulant intitulé "*Period*" permet de changer la période du *dataset* si celui-ci a une période inférieure ou égale à 5 minutes. Les options permettent d'afficher un point toutes les 5, 10, 15, 20, 25 et 30 minutes, ou de rétablir la période d'origine du *dataset*.

Enfin, deux diagrammes agrémentent l'application avec des informations complémentaires :

- Celui de gauche est un **diagramme en barres empilées** (*stacked bar chart*), affichant pour chaque espèce ACSM la moyenne de la concentration sur la totalité du *dataset*.
- Celui de droite est un **diagramme circulaire** (*pie chart*) offrant un aperçu rapide et global sur la composition atmosphérique. La proportion de chaque espèce (en pourcentage) dans la composition atmosphérique y est indiquée.

Il est à noter que tous les objets affichés à l'écran appartiennent à la librairie Bokeh. Je ne rentrerai pas dans les détails techniques du fonctionnement de l'application, mais sachez que l'application est exécutée par un serveur Bokeh, s'appuyant sur un fichier Python `main.py`. De plus, lorsque l'utilisateur interagit avec un *widget*, une fonction *callback* est exécutée, permettant de réaliser les actions liées au *widget*.

Il est important de souligner que les données utilisées pour réaliser ces diagrammes ainsi que les calculs statistiques sont uniquement les **données valides**.

Par soucis de concision et de clarté, je ne rentrerai pas dans l'explication détaillée du code de l'application.

7.4. Développement de la deuxième version de l'application

Après discussion avec mon tuteur, j'ai développé une deuxième version de mon application en m'appuyant sur ses remarques, celles des scientifiques, des collègues, mais aussi sur mes propositions personnelles. L'enjeu était de pouvoir **afficher plusieurs espèces à la fois** sur le graphe principal, ce qui n'était pas possible dans la première version. De plus, afin de répondre aux besoins des scientifiques, il a été décidé de proposer **plusieurs choix de représentation graphique.**

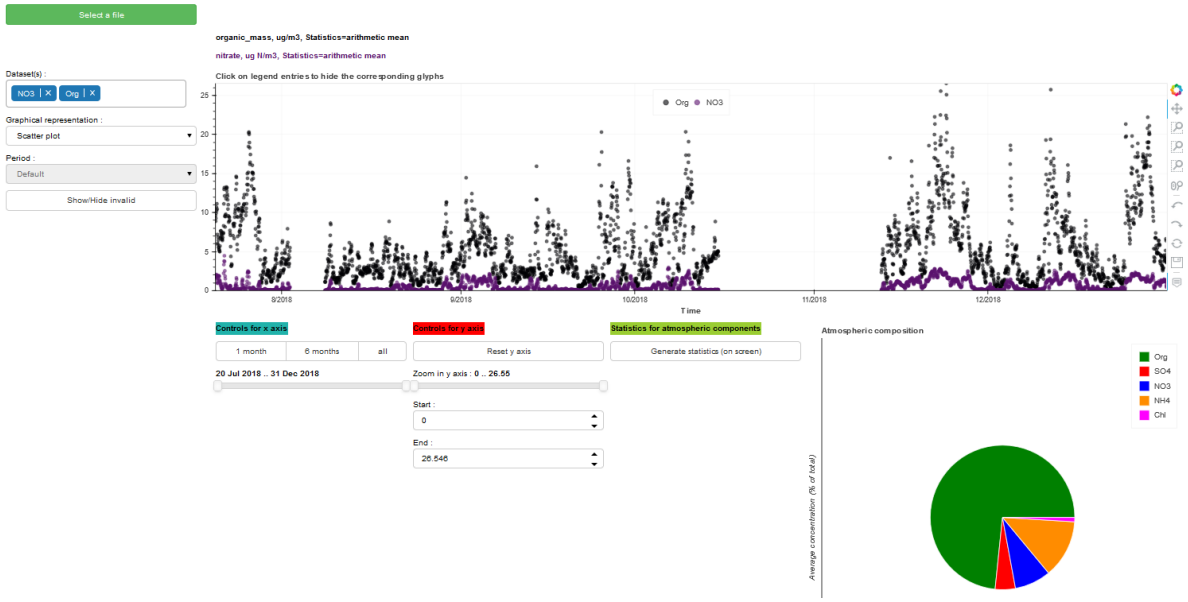


Figure 12 : Vue d'ensemble de la deuxième version de mon application avec visualisation des données du fichier de la figure 9

Cette deuxième version, enrichie par les remarques pertinentes que j'ai pu recevoir, propose diverses nouveautés :

- Il est désormais possible de sélectionner plusieurs *datasets* à la fois, grâce à un *multi choice*. À chaque clic sur la boîte, un menu déroulant apparaît avec lequel on peut faire sa sélection. Il est également possible de supprimer un *dataset* en cliquant sur la croix associée. On ne peut ajouter/supprimer qu'un *dataset* à la fois. Chaque *dataset* a sa couleur associée, en accord avec la couleur du titre.
- L'utilisateur peut aussi choisir le type de représentation graphique des *datasets* grâce au menu déroulant "*Graphical representation*". Les options disponibles sont "*Scatter plot*" (nuage de points) et "*Stacked bar chart*" (diagramme en barres empilées). Une info-bulle est disponible pour les deux types de représentation graphique.

Il est utile de noter que pour des raisons de lisibilité, une **légende interactive** a été développée : l'utilisateur peut facilement afficher/cacher un *scatter plot* ou un *stacked bar chart* par un simple clic sur la légende.

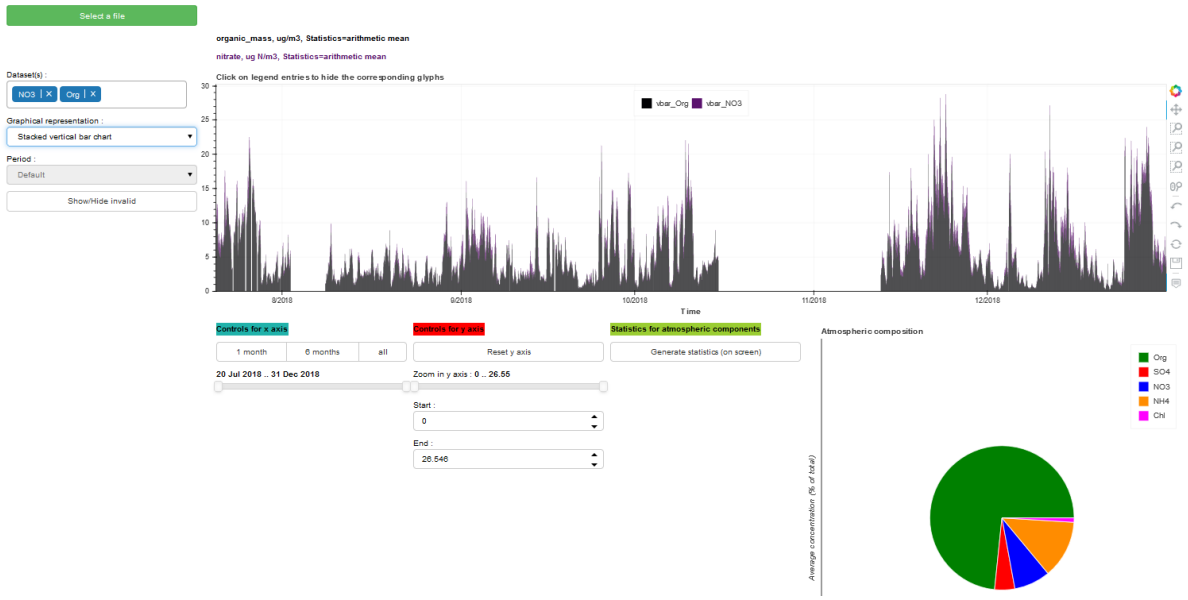


Figure 13 : Vue d'ensemble de la deuxième version de mon application avec la représentation graphique en barres empilées

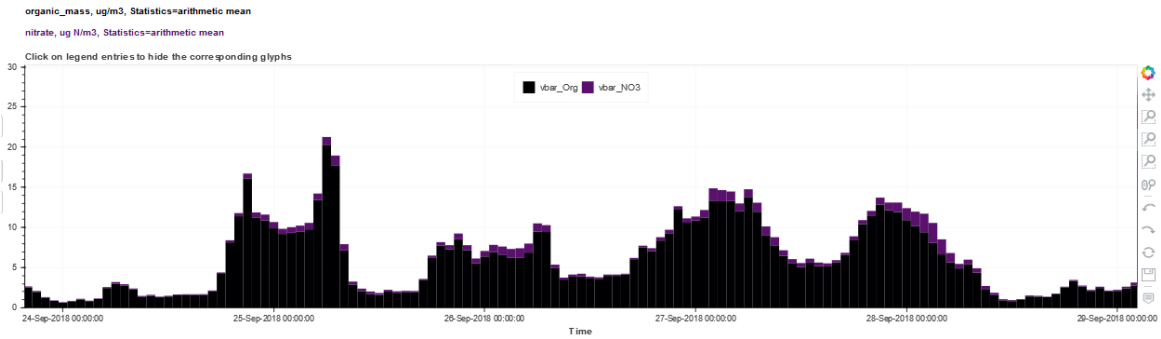


Figure 14 : Vue zoomée du diagramme en barres empilées de la figure 13

La représentation en barres empilées est très pratique pour avoir un rapide aperçu de la dominance d'une espèce chimique par rapport aux autres au cours du temps. Sur la figure 14, nous pouvons clairement voir que la matière organique domine sur les nitrates.

De plus, deux améliorations importantes ont été réalisées en termes d'ergonomie et de présentation :

- Les *widgets* du panneau interactif ont été déplacés et classés en colonnes par utilité grâce à une étiquette. Il existe désormais trois colonnes de *widgets* : les *widgets* de contrôle de l'axe x ("*Controls for x axis*"), de contrôle de l'axe y ("*Controls for y axis*") et de calcul statistique pour les composants atmosphériques ("*Statistics for atmospheric components*").
- La palette de couleurs pour le *pie chart* a été modifiée, suite aux remarques des scientifiques lors du workshop ACTRIS du 12/11/2020 (cf. diagramme de Gantt

page 34). Les couleurs retenues pour les composants atmosphériques sont les couleurs classiques utilisées par les chercheurs dans ce domaine.

7.5. Implémentation de l'application au sein du projet CAMS

7.5.1. Qu'est-ce que le projet CAMS ?

Le projet CAMS (*Copernicus Atmosphere Monitoring System*) est un **projet européen** dont l'objectif est la surveillance de l'atmosphère.



Figure 15 : Logo du programme Copernicus

Ce projet fait partie du **programme Copernicus**, le programme d'observation de la Terre de l'Union européenne. Il s'intéresse à notre planète et à son environnement pour le bénéfice de tous les citoyens européens. Il offre des services d'information basés sur l'observation de la Terre par satellite et des données in situ[12].

Le programme est coordonné et géré par la Commission européenne. Il est mis en œuvre en partenariat avec les États membres, l'Agence spatiale européenne (ESA), l'Organisation européenne pour l'exploitation de satellites météorologiques (EUMETSAT), le Centre européen de prévisions météorologiques à moyen terme (ECMWF), les agences de l'UE et Mercator Océan.

De vastes quantités de données mondiales provenant de satellites et de systèmes de mesure terrestres, aériens et maritimes sont utilisées pour fournir des informations afin d'aider les prestataires de services, les autorités publiques et les autres organisations internationales à améliorer la qualité de vie des citoyens européens. Les services d'informations fournis sont accessibles gratuitement et librement à ses utilisateurs.

7.5.2. Comment l'application développée intervient-elle dans ce projet ?

La mission du projet CAMS est de collecter, traiter, visualiser, valider et formater des données ACSM en temps quasi réel afin d'identifier et de comprendre les sources d'émissions de particules fines. Ces données, accessibles au niveau mondial, peuvent également être utilisées pour les besoins locaux et régionaux, afin d'aider les populations à mieux comprendre notre planète et à gérer de manière durable notre environnement.

L'objectif était donc d'intégrer l'application développée précédemment afin d'assurer la visualisation de ces données, indispensable aux scientifiques afin d'effectuer la validation des données.

7.5.3. Détail du projet CAMS

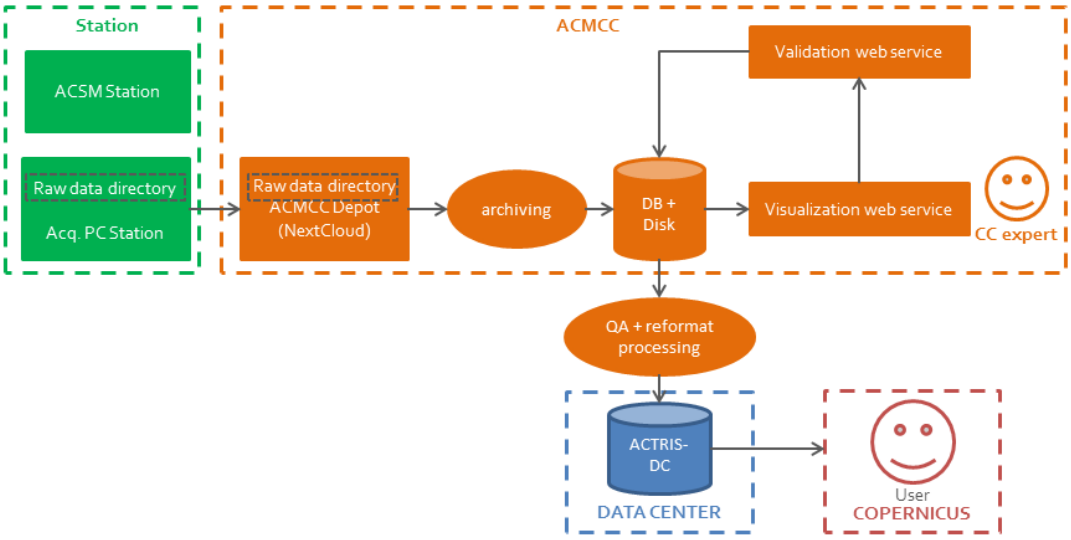


Figure 16 : Schéma du projet CAMS

Le fonctionnement global du projet est le suivant :

- Tout d'abord, les données sont collectées par un instrument ACSM appartenant à une station en Europe. À terme, 16 stations participeront au projet CAMS. En France, les stations du SIRTA à Paris et de Clermont-Ferrand sont notamment impliquées.
- Les données collectées par l'instrument sont accessibles depuis le *raw data directory*, c'est-à-dire depuis le répertoire du PC d'acquisition directement branché à l'instrument.
- Ensuite, ces données sont envoyées vers l'ACMCC (*Aerosol Chemical Monitor Calibration Centre*), le centre de calibration de la chimie des aérosols, basé à Gif-sur-Yvette et sous la responsabilité du SIRTA/LSCE. Plus précisément, elles sont synchronisées sur un NextCloud, similaire à un OneDrive par exemple.
- Archivées dans la base de données ACMCC et sur disque, les données sont par la suite visualisées à l'aide d'un service web de visualisation. C'est à ce moment qu'entre en jeu mon application.
- Une fois les données visualisées, un service web de validation prend le relai afin de détecter et de marquer les données invalides.
- Puis, les données traitées sont renvoyées sur la base de données et subissent un processus de reformatage, assurant leur qualité.

- Ces données sont ensuite partagées avec le data center d'ACTRIS basé au NILU en Norvège et stockées dans leur base de données EBAS.
- Enfin, elles sont mises à disposition des utilisateurs Copernicus qui accèdent à ces données depuis l'ECMWF, le data center du programme Copernicus.

7.5.4. Application développée pour le projet CAMS

L'application livrée pour ce projet européen correspond à une troisième version de l'application développée précédemment. L'essentiel du *dashboard* a été conservé, mais certains *widgets* ont disparu et de nouveaux ont été implémentés. Le changement radical réside dans la **plage d'affichage des données** et leur **lecture**. Ainsi, l'utilisateur peut choisir à l'aide d'une **carte** à quel site appartiennent les données à visualiser. La sélection s'effectue en cliquant sur un cercle, et les informations relatives au site sont affichées à l'aide d'une info-bulle. De plus, alors que la deuxième version lisait un fichier contenant 5 mois de données, l'application permet un affichage des données d'**une journée**, en compilant tous les fichiers de données correspondant à cette journée et au site sélectionné (un fichier par mesure). Ici, les fichiers de données sont récupérés dans la base de données d'ICARE et n'ont plus l'obligation d'être déposés dans le répertoire de l'application.

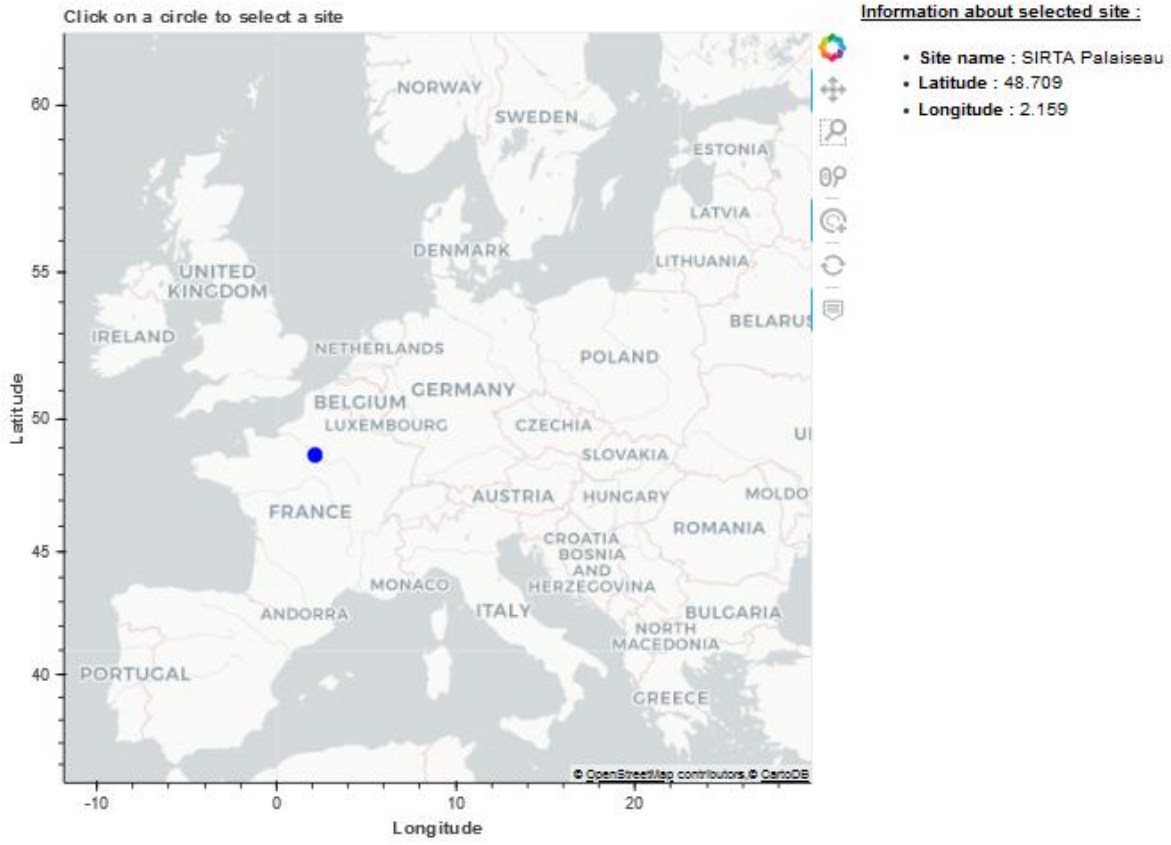


Figure 17 : Vue de la carte de la troisième version de mon application (partie supérieure du *dashboard*)



Figure 18 : Vue d'ensemble de la troisième version de mon application (partie inférieure du *dashboard*)

Il est important de souligner que contrairement aux anciennes versions de l'application, les données affichées à l'écran sont toutes les données présentes dans le fichier : il n'y a **pas d'informations sur la qualité des données** (pas de flag). La validation des données sera effectuée par la suite comme expliqué plus haut.

Concernant les nouveaux *widgets* disponibles, nous pouvons notamment citer :

- Un calendrier (*DatePicker*) permettant de sélectionner la date des données à visualiser ;
- Un duo de boutons "*Show error enveloppe*" et "*Hide error enveloppe*" permettant d'afficher ou de cacher l'enveloppe d'erreur pour toutes les espèces ACSM à l'écran. Ces enveloppes sont calculées en fonction de données d'erreur sur la mesure fournies dans les fichiers.

Il est à noter que seuls les *widgets* de contrôle de l'axe y et de calcul statistique ont été conservés. L'application a été déployée sur une URL sécurisée afin que les scientifiques participant au projet puissent la tester et nous faire part de leurs remarques.

J'ai d'ailleurs pu présenter mon application aux membres du projet CAMS lors d'un meeting où j'ai réalisé une démonstration en anglais de mon interface.

8. Livrables produits et préconisations pour la suite

8.1. Livrables produits

En ce qui concerne le projet CAMS, j'ai effectué la livraison de l'application sur une URL sécurisée comme expliqué ci-dessus. J'ai également mis le code à disposition de l'équipe sur le GitLab d'ICARE.

En parallèle, suite à la demande de livraison de l'application à l'initiative du Centre Spatial Universitaire de Grenoble, j'ai effectué le packaging de la deuxième version de mon application. J'ai notamment mis en ligne le code sur le GitLab d'ICARE et révisé toute la *docstring*. De plus, j'ai ajouté une licence, des fichiers README, CHANGELOG et un dossier doc dans lequel j'ai fourni un guide d'utilisation et un tutoriel vidéo d'utilisation du *dashboard*. Ce dernier a été mis en ligne sur la plateforme YouTube et est disponible à l'adresse suivante : https://youtu.be/S8L7gK0Ey2c.

8.2. Préconisations pour la suite

Après mon départ d'ICARE, l'enjeu sera d'assurer la continuité du projet CAMS, et en particulier :

- D'implémenter les évolutions sur la base des retours des utilisateurs (maintenance évolutive) ;
- D'implémenter les autres sites (16 à terme), de lire et visualiser leurs données ;
- D'intégrer la prise en compte de différents instruments (pas seulement des données ACSM, mais aussi des données issues d'un étalomètre par exemple) ;
- De réutiliser le travail fourni pour CAMS au sein du projet suivant nommé URBAN-RI (URBAN Research Infrastructure) qui consiste à calculer la répartition des différentes sources d'aérosol (*source apportionment*).

9. Organisation du travail

Suite à la mise en place du deuxième confinement le 29 octobre, j'ai débuté ma période de travail à distance début novembre. L'exercice était inédit puisque j'avais jusque-là travaillé en présentiel depuis septembre. J'ai donc dû m'adapter à cette situation en poursuivant le développement de mon application en complète autonomie. Le télétravail ayant été prolongé après la fin du confinement, j'ai ainsi terminé la deuxième version de mon application à distance et mis en place une troisième version pour le projet CAMS. Je me suis organisée en planifiant les tâches à effectuer, notamment en notant sur quels aspects ou parties de mon application je devais travailler. Cette méthode m'a été utile pour ne pas m'égarer au cours du développement et pour séparer les points à traiter en priorité des détails superflus. Par

conséquent, j'ai pris énormément d'initiatives, et cela m'a beaucoup plus car j'ai pu mettre en œuvre mes idées et les voir se concrétiser. Je n'ai également pas hésité à me référer à mon tuteur quand j'avais besoin de son avis sur mes idées. J'ai aussi pu lui faire tester mon application afin d'avoir ses retours et ses suggestions en partageant mon code sur le GitLab d'AERIS/ICARE, ce qui m'a permis de découvrir les commandes Git de base et de me former à cet outil indispensable utilisé par les équipes de développeurs en entreprise.

Ainsi, il m'a fallu étoffer la précision de mes explications afin de me faire comprendre par mon tuteur à l'écrit. Le plus difficile a été la diminution des contacts avec l'équipe et mon tuteur, avec lequel il était plus compliqué d'échanger sur des points techniques à distance. Cependant, j'ai alterné chaque semaine avec une journée en présentiel le mercredi qui me permettait de faire le point sur les problématiques rencontrées et le travail effectué. Enfin, l'utilisation du service de messagerie instantanée Mattermost m'a permis de garder un lien avec l'équipe pendant toute la durée de la période de télétravail.

Conclusion

Ces cinq mois de stage réalisés au sein d'ICARE ont été extrêmement formateurs et instructifs pour moi, tant sur le plan personnel que professionnel. En ce qui concerne l'aspect purement technique, j'ai pu améliorer ma connaissance de la programmation en Python de façon exponentielle, en dépassant largement le niveau préalablement acquis en Classes Préparatoires, notamment grâce à l'apprentissage de la POO et à la découverte de nouvelle librairies. De plus, j'ai eu l'occasion de me former à l'utilisation de JupyterLab, qui deviendra sans aucun doute la solution de développement absolue pour tout *data scientist* dans quelques années. En parallèle, j'ai également beaucoup appris sur le domaine des sciences de l'atmosphère et sur le fonctionnement d'un data center grâce à mon tuteur et aux projets menés par toute l'équipe.

Sur le plan personnel, ce stage m'a énormément plu de par sa conscience écologique et citoyenne qui me tient à cœur. En participant activement à un projet européen de surveillance de l'atmosphère, j'ai pu me rendre utile et contribuer à ma façon à la sensibilisation pour la protection de l'environnement. In fine, mon expérience au sein de ce Centre de Données et Services pour l'atmosphère m'a ouvert les yeux sur mon projet professionnel. En effet, ce stage me pousse à poursuivre mes études en me focalisant sur un parcours axé spatial et orienté informatique. J'ai ainsi pu choisir mes électifs dans ce sens, et mon choix de double-diplôme en spatial est confirmé. Enfin, ce stage me conforte dans l'idée que je souhaite exercer mon métier dans un domaine du spatial mêlant mécanique et électronique/informatique, comme la construction de robots pour l'exploration spatiale.

Annexes : Fonctionnement de l'instrument ACSM

Principe de fonctionnement

L'ACSM utilise la spectrométrie de masse. C'est une technique physique d'analyse permettant de détecter et d'identifier des molécules d'intérêt par mesure de leur masse, et de caractériser leur structure chimique. Son principe réside dans la séparation en phase gazeuse de molécules chargées (ions) en fonction de leur **rapport masse/charge** (m/z). Ainsi, le rôle d'un spectromètre de masse est de compter les ions afin de déterminer la concentration de chaque espèce dans l'échantillon.

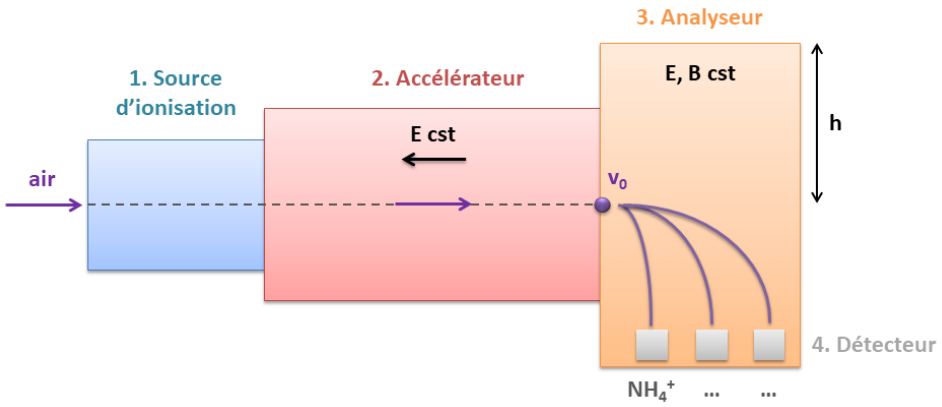


Figure 19 : Schéma de l'ACSM avec analyseur à temps de vol

Étapes de fonctionnement

1. **Ionisation :** L'échantillon étudié est vaporisé et ionisé. L'ionisation entraîne une accumulation d'énergie qui, en se dissipant, provoque la rupture des liaisons des fragments caractéristiques des molécules. À ce stade, on obtient un mélange d'ions de fragmentation. Une source d'ionisation peut être utilisée soit en mode positif pour étudier les ions positifs, soit en mode négatif pour étudier les ions négatifs. Plusieurs types de sources existent et sont utilisés en fonction du résultat recherché et des molécules analysées.
2. **Accélération :** Les ions formés sont extraits de la source, focalisés et accélérés en passant entre deux plaques soumises à une différence de potentiel. Le champ électrique étant constant, les ions ont la même énergie cinétique à la sortie du champ d'accélération, et donc, en sortie, évoluent dans un mouvement rectiligne uniforme.
3. **Séparation :** Les ions sont filtrés suivant leur rapport m/z par un analyseur. Plus précisément, en mesurant le temps mis par la particule ionisée pour atteindre le détecteur, on peut séparer les ions dans le temps, à condition qu'ils partent tous en même temps de la fente d'entrée de l'analyseur. Les particules ayant des masses différentes et des énergies cinétiques identiques, leurs vitesses sont donc différentes. En particulier, la vitesse croît en fonction de la masse. L'analyseur décrit ici est un analyseur à temps de vol (TOF), mais il existe également un deuxième type d'analyseur utilisé pour les ACSM : l'analyseur quadripolaire.
4. **Détection :** Après séparation, les ions terminent leur course en venant frapper un détecteur qui détecte et amplifie le courant ionique très faible. En connaissant les dimensions de l'appareil et la masse des ions, il est possible de déterminer l'endroit précis de l'impact. Ainsi, plus les ions sont nombreux, plus le courant est important. Le détecteur amplifie le signal obtenu pour qu'il puisse être traité informatiquement.
5. Enfin, le **spectre de masse** est affiché, révélateur de la composition de l'échantillon. Il présente la relative abondance en fonction du rapport masse/charge.

Annexes : Diagramme de Gantt

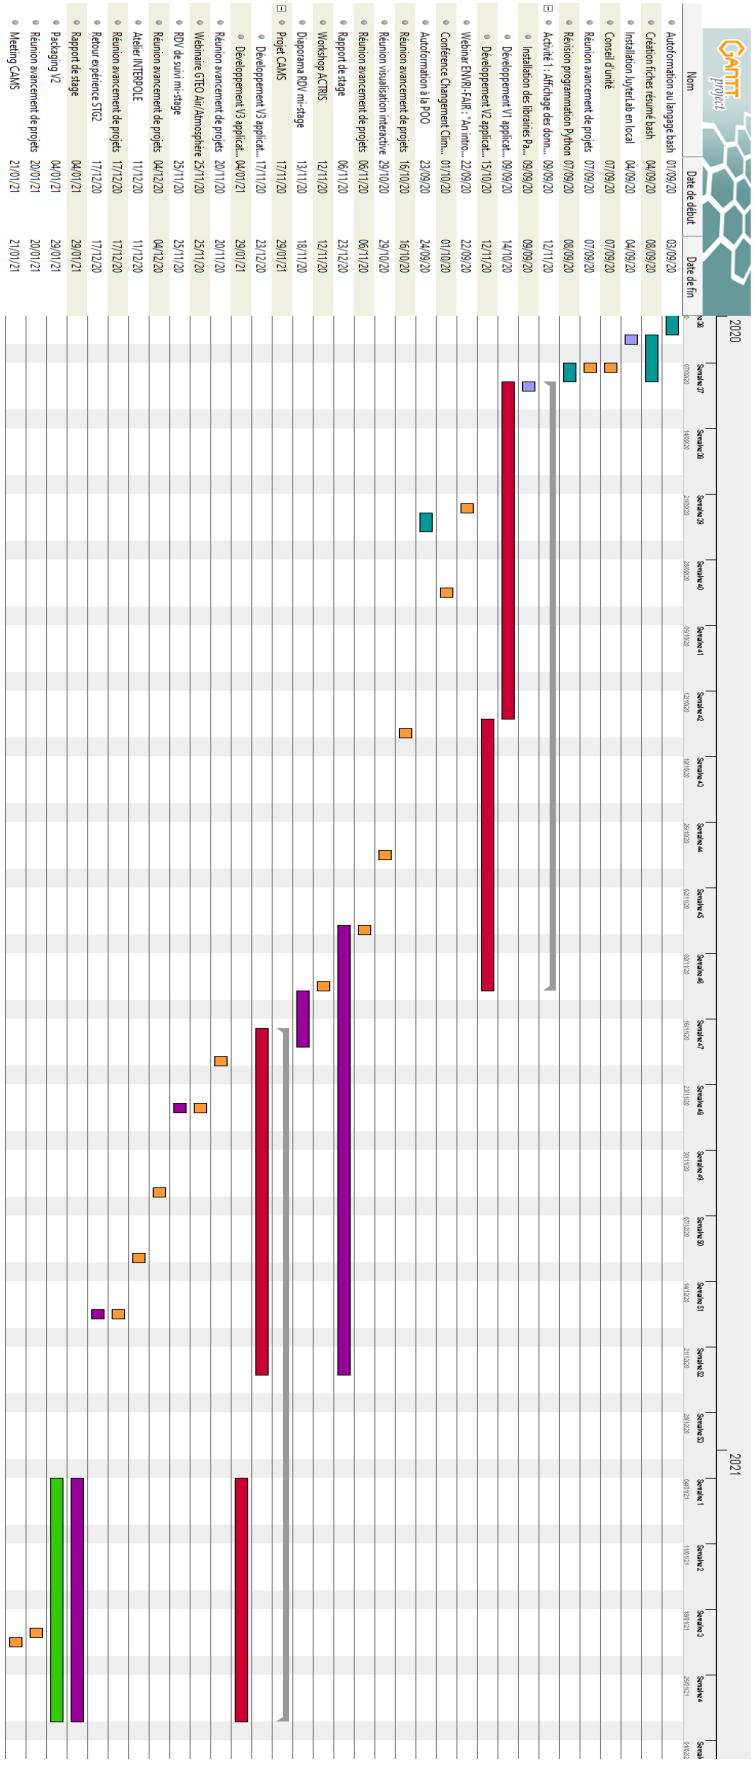


Table des figures

Figure 1 : Localisation des centres de données constitutifs d'AERIS 7
(carte générée par l'Institut National de l'Information Géographique Forestière) 7
Figure 2 : Organigramme d'ICARE au 09/11/2020 8
Figure 3 : Photographie du SAS réfrigéré de la salle des machines 9
Figure 4 : Résumé des services d'accès aux données proposés par ICARE 10
Figure 5 : Résumé des services web autour de la donnée proposés par ICARE 11
Figure 6 : Diagramme de GANTT de la chronologie du stage (version agrandie en annexes) 13
Figure 7 : Exemple de notebook Jupyter de visualisation de données 17
Figure 8 : Photographie d'un ACSM 18
Figure 9 : À gauche : extrait de l'en-tête d'un fichier ACSM au format NASA-Ames, à droite : extrait des données ACSM de ce fichier 19
Figure 10 : Vue d'ensemble de l'application développée par mon tuteur avec visualisation des données du fichier de la figure 9 22
Figure 11 : Vue d'ensemble de la première version de mon application avec visualisation des données du fichier de la figure 9 23
Figure 12 : Vue d'ensemble de la deuxième version de mon application avec visualisation des données du fichier de la figure 9 25
Figure 13 : Vue d'ensemble de la deuxième version de mon application avec la représentation graphique en barres empilées 26
Figure 14 : Vue zoomée du diagramme en barres empilées de la figure 13 26
Figure 15 : Logo du programme Copernicus 27
Figure 16 : Schéma du projet CAMS 28
Figure 17 : Vue de la carte de la troisième version de mon application (partie supérieure du *dashboard*) 29
Figure 18 : Vue d'ensemble de la troisième version de mon application (partie inférieure du *dashboard*) 30
Figure 19 : Schéma de l'ACSM avec analyseur à temps de vol 33

Table des abréviations

Acronyme	Définition
ACTRIS	*Aerosol, Clouds and Trace Gases Research Infrastructure* Infrastructure de recherche sur les aérosols, les nuages et les gaz traces
AERIS	Infrastructure française de données et services pour l'atmosphère
CNES	Centre National d'Etudes Spatiales
CNRS	Centre National de la Recherche Scientifique
ECMWF	*European Centre for Medium-Range Weather Forecasts* Centre européen pour les prévisions météorologiques à moyen terme
ESA	*European Space Agency* Agence Spatiale Européenne
ESPRI	Ensemble de Services pour la Recherche à l'Institut Pierre Simon Laplace (IPSL)
EUMETSAT	*European Organisation for the Exploitation of Meteorological Satellites* Organisation européenne pour l'exploitation des satellites météorologiques
ISRO	*Indian Space Research Organisation* Organisation indienne pour la recherche spatiale
LOA	Laboratoire d'Optique Atmosphérique
LSCE	Laboratoire des Sciences du Climat et de l'Environnement
NASA	*National Aeronautics and Space Administration* Administration nationale de l'aéronautique et de l'espace
NILU	*Norwegian Institute for Air Research* Institut norvégien de recherche sur l'air
POO	Programmation Orientée Objet
SATMOS	Service d'Archivage et de Traitement Météorologique des Observations Satellitaires
SEDOO	Services de données de l'Observatoire Midi-Pyrénées
SIRTA	Site Instrumental de Recherche par Télédétection Atmosphérique

Glossaire

Numéro	Terme	Définition
1	Aérosol	Ensemble de fines particules, solides ou liquides, d'une substance chimique ou d'un mélange de substances, en suspension dans un milieu gazeux et émis par les activités humaines ou naturelles (volcans, incendies de forêt), intervenant à l'échelle planétaire et locale dans les phénomènes de pollution de l'air et d'allergies.
2	Données de télédétection	Contrairement aux données in situ, données mesurées à distance, que ce soit au sol ou au moyen de satellites
3	Cluster	Regroupement de plusieurs ordinateurs indépendants appelés nœuds (*node*), afin de permettre une gestion globale et de dépasser les limitations d'un ordinateur pour augmenter la disponibilité, faciliter la montée en charge, permettre une répartition de la charge, faciliter la gestion des ressources (processeur, mémoire vive, disques durs, bande passante réseau).
4	FTP	Le FTP (*File Transfer Protocol*) est un protocole réseau standard qui permet de transférer les fichiers entre deux hôtes.
5	API REST	API REST (*Representational State Transfer Application Program Interface*) est un style architectural qui permet aux logiciels de communiquer entre eux sur un réseau ou sur un même appareil. Le plus souvent, les développeurs utilisent des API REST pour créer des services web. Souvent appelés services web RESTful, REST utilise des méthodes HTTP pour récupérer et publier des données entre un périphérique client et un serveur.
6	Data science	Science des données ; domaine interdisciplinaire qui utilise des méthodes, des processus, des algorithmes et des systèmes scientifiques pour extraire des connaissances et des idées de nombreuses données structurelles et non structurées. Elle est souvent associée aux Big Data et à l'analyse des données. Elle utilise des techniques et des théories tirées de nombreux domaines dans le contexte des mathématiques, des statistiques, de l'informatique, de la théorie et des technologies de l'information.
7	Dashboard	Tableau de bord ; outil/interface présentant les indicateurs essentiels à la réalisation d'un objectif ou à un processus, le tout assimilable en un coup d'œil.
8	Markdown	Langage très simple qui permet d'écrire du HTML de façon raccourcie
9	NASA-Ames (format)	Format officialisé pour la première fois au Centre de recherche Ames de la NASA en Californie afin d'établir des règles uniformes pour enregistrer des données et faciliter leur échange. Il devait répondre aux exigences suivantes : - Être portable (lisible sur n'importe quelle machine par n'importe quel langage de programmation) ; - Être auto-descriptif : les données devaient inclure une pièce jointe contenant toutes les informations nécessaires pour les lire, les comprendre et les interpréter - garantissant ainsi l'autonomie du lecteur ; - Être lisible par les humains.
10	FFI	*File Format Index* ; nombre à 4 chiffres indiquant le style de format NASA-Ames du fichier. Il existe neuf styles qui respectent tous une structure globale commune mais prévoient des fonctionnalités différentes adaptées à différents cas (selon le nombre de variables indépendantes, si leurs valeurs sont régulièrement espacées, etc.).
11	CSV (format)	*Comma-separated values* ; format texte représentant des données tabulaires sous forme de valeurs séparées par des virgules.
12	Données in situ	Données prélevées directement sur site